Classificação Multirrótulo e Combinação de Modelos na Predição de Reações Adversas a Medicamentos

Vitor Rodrigues da Mata

Departamento de Computação – Universidade Federal de São Carlos (UFSCar)
Rod. Washington Luís, km 235 – 13565-905 – São Carlos – SP – Brasil

vitormata@estudante.ufscar.br

Multi-label Classification and Model Combination for Adverse Drug Reaction Prediction

Abstract. *Predicting from molecular structure which organ systems a drug may affect supports early safety screening. In the SIDER dataset (1,427 drugs, 27 organ classes), labels are strongly dependent and 69% of test drugs show a label combination unseen in training. We compare BR, LP, CC, ML-kNN and model combination methods (EBR, ECC, RAkEL, stacking) with Random Forest and Logistic Regression base learners. A trivial baseline comes close to the best methods on example-based metrics. Modeling label dependence yields small ranking gains with Random Forest and large gains with Logistic Regression, for which LP with marginal decoding is best; RAkEL with intermediate k beats both BR and LP, and the useful source of ensemble diversity depends on the stability of the base learner.*

Resumo. *Prever, a partir da estrutura molecular, quais sistemas do organismo um fármaco pode afetar auxilia a triagem precoce de segurança. Na base SIDER (1.427 fármacos, 27 classes de órgãos), os rótulos são fortemente dependentes e 69% dos fármacos de teste têm combinações ausentes do treino. São comparados BR, LP, CC, ML-kNN e métodos de combinação de modelos (EBR, ECC, RAkEL, empilhamento) com Random Forest e Regressão Logística. Uma linha de base trivial fica próxima dos melhores métodos nas métricas por exemplo. Modelar a dependência traz ganhos pequenos de ordenação com Random Forest e grandes com Regressão Logística, em que o LP com decodificação marginal é o melhor; o RAkEL com k intermediário supera BR e LP, e a fonte útil de diversidade depende da estabilidade do classificador base.*

1 Introdução

Reações adversas a medicamentos (RAMs) estão entre as causas relevantes de morbidade e de internação: uma meta-análise clássica estimou que RAMs graves acometem cerca de 6,7% dos pacientes hospitalizados [Lazarou et al. 1998]. Como muitas

reações só são caracterizadas depois que o fármaco chega ao mercado, prever — a partir apenas da estrutura molecular — quais sistemas do organismo um composto tende a afetar é uma ferramenta de triagem atraente nas fases iniciais do desenvolvimento.

O problema é naturalmente *multirrótulo*: um mesmo fármaco provoca reações em vários sistemas ao mesmo tempo. Na base SIDER [Kuhn et al. 2016], na versão do *benchmark* MoleculeNet [Wu et al. 2018], cada um dos 1.427 fármacos está associado, em média, a 15,3 das 27 classes de órgãos e sistemas do dicionário MedDRA. Duas características tornam essa base um caso de estudo especialmente fértil para os métodos vistos na disciplina: (i) os rótulos são fortemente dependentes — *todos* os 351 pares de rótulos apresentam correlação positiva — e (ii) as combinações de rótulos são quase todas raras, com 1.088 combinações distintas para 1.427 exemplos.

Este trabalho combina dois temas da disciplina, *classificação multirrótulo* e *combinação de modelos*, para investigar como explorar essas dependências. Três questões de pesquisa (QP) guiam o estudo: **QP1** — métodos que modelam a dependência entre rótulos (cadeias, *Label Powerset*, RAkEL, empilhamento) superam a Relevância Binária, que trata cada rótulo isoladamente? **QP2** — como o *Label Powerset* se comporta quando a maioria das combinações de teste nunca apareceu no treino, e o RAkEL de fato funciona como meio-termo entre os dois extremos? **QP3** — em ensembles de cadeias, qual fonte de diversidade, a ordem dos rótulos ou a reamostragem *bootstrap*, produz ganho na combinação?

As contribuições são: (a) uma comparação controlada de nove estratégias multirrótulo e uma linha de base trivial, com dois classificadores base, validação cruzada estratificada iterativa e testes estatísticos corrigidos; (b) um experimento que *decompõe* a diversidade de ensembles de cadeias em diversidade de ordem e de reamostragem, medida pela estatística Q; e (c) uma análise de sensibilidade do RAkEL que percorre o espectro entre BR ($k = 1$) e LP ($k = 27$). Código, dados, resultados e figuras estão em https://github.com/VitordaMata12/Aprendizado-de-Maquina-2/tree/main/Trabalho1. A Seção 2 resume os fundamentos e trabalhos relacionados; a Seção 3 descreve dados e protocolo; a Seção 4 apresenta e discute os resultados; e a Seção 5 conclui.

2 Fundamentação e Trabalhos Relacionados

2.1 Classificação multirrótulo

Seja $\mathscr{L} = \{\lambda_1, \ldots, \lambda_q\}$ o conjunto de rótulos. Cada exemplo $\mathbf{x}_i$ está associado a um subconjunto $Y_i \subseteq \mathscr{L}$, representado pelo vetor binário $\mathbf{y}_i \in \{0,1\}^q$. Os métodos dividem-se em *transformação do problema*, que convertem a tarefa em problemas monorrótulo, e *adaptação de algoritmos*, que modificam um algoritmo para lidar diretamente com conjuntos de rótulos [Zhang and Zhou 2014, Faceli et al. 2021].

Na **Relevância Binária** (BR), treinam-se q classificadores binários independentes, um por rótulo [Boutell et al. 2004]. É simples e escalável, mas ignora a dependência entre rótulos. No ***Label Powerset*** (LP), cada combinação distinta de rótulos vira uma classe de um problema multiclasse; a dependência é capturada por construção, mas o número de classes pode chegar a $\min(n, 2^q)$, muitas com um único exemplo, e o modelo não consegue predizer combinações ausentes do treino. O **Encadeamento de Clas-**

sificadores (CC) treina q classificadores binários em sequência: o j-ésimo recebe os atributos e os rótulos dos $j-1$ anteriores, que na predição são substituídos pelas predições [Read et al. 2011]. O resultado depende da ordem escolhida e erros podem se propagar ao longo da cadeia; por isso, os mesmos autores propõem o **ECC**, que combina m cadeias com ordens aleatórias treinadas em amostras *bootstrap*. O **RAkEL** [Tsoumakas et al. 2011] é um meio-termo entre BR e LP: treina LPs sobre m subconjuntos aleatórios de k rótulos e combina, para cada rótulo, as saídas dos LPs que o contêm. Entre os métodos de adaptação, o **ML-kNN** [Zhang and Zhou 2007] encontra os k vizinhos mais próximos e aplica a regra de Bayes (estimativa MAP) sobre a contagem de vizinhos que possuem cada rótulo.

Um ponto teórico importante orienta a interpretação dos resultados: modelar a dependência não ajuda igualmente todas as métricas. Como demonstrado em [Dembczyński et al. 2012], para perdas decomponíveis por rótulo, como a *Hamming loss*, o classificador ótimo depende apenas das probabilidades marginais de cada rótulo — exatamente o que o BR estima —, enquanto a acurácia exata exige a moda da distribuição conjunta. Assim, ganhos de métodos que exploram dependências devem aparecer primeiro nas métricas conjuntas e de ordenação, e não necessariamente na *Hamming loss*.

2.2 Combinação de modelos

Um ensemble só supera seus membros se estes forem melhores que o acaso e cometerem erros pouco correlacionados [Hansen and Salamon 1990]. A diversidade pode ser obtida manipulando os dados de treino, como no *bagging* [Breiman 1996] e na *Random Forest* [Breiman 2001], ou injetando aleatoriedade no próprio algoritmo. As saídas podem ser combinadas por regras fixas, como soma, média, produto ou voto [Kittler et al. 1998], ou por um meta-classificador treinado sobre as saídas dos modelos base, na *generalização por pilha* (*stacking*) [Wolpert 1992]. No cenário multirrótulo, o empilhamento do BR (também chamado 2BR) usa no meta-nível os escores de *todos* os rótulos para predizer cada um deles, aprendendo as dependências de forma explícita [Godbole and Sarawagi 2004]. Para medir a diversidade entre dois classificadores, pode-se usar a tabela de concordância [Kuncheva and Whitaker 2003] com a (ambos acertam), b (só o primeiro acerta), c (só o segundo acerta) e d (ambos erram), da qual derivam-se a medida de desacordo $(b+c)/N$ e a estatística $Q = (ad-bc)/(ad+bc)$, que vale 1 quando os dois sempre acertam e erram juntos.

2.3 Predição de efeitos colaterais

A SIDER reúne efeitos colaterais extraídos de bulas de medicamentos comercializados [Kuhn et al. 2016]. O MoleculeNet [Wu et al. 2018] agrupou esses efeitos nas 27 classes de órgãos e sistemas do MedDRA e incluiu a tarefa em seu *benchmark*, no qual ela figura entre as mais difíceis: os valores de AUC-ROC relatados ficam tipicamente entre 0,6 e 0,7, tanto para modelos clássicos quanto para redes em grafos. Em [Zhang et al. 2015], a predição de efeitos colaterais foi tratada explicitamente como problema multirrótulo, combinando ML-kNN com seleção de atributos e ensembles sobre várias descrições dos fármacos (subestruturas, alvos, vias, indicações). Diferentemente desses trabalhos, cujo objetivo é o maior desempenho possível com múltiplas fontes de informação, o foco aqui é analítico: usar uma única representação, puramente estrutural,

para isolar o efeito das estratégias multirrótulo e de combinação.

3 Materiais e Métodos

3.1 Base de dados

Utilizou-se a versão MoleculeNet da SIDER: 1.427 fármacos descritos por sua estrutura em notação SMILES e 27 rótulos binários, cada um indicando se há ao menos um efeito colateral registrado na respectiva classe de órgãos e sistemas. A Tabela 1 resume as estatísticas multirrótulo e a Figura 1 mostra a prevalência de cada rótulo e a distribuição da cardinalidade.

Tabela 1: Estatísticas multirrótulo da base SIDER.

Fármacos (n)	1.427	Combinações distintas de rótulos	1.088
Rótulos (q)	27	Combinações com uma só ocorrência	967
Atributos	379	Fármacos com combinação única	67,8%
Cardinalidade (média $\pm$ dp)	$15{,}3 \pm 6{,}0$	Combinação inédita no teste*	69,3%
Densidade	0,568	ϕ médio entre pares de rótulos	0,254
MeanIR / MaxIR	4,5 / 59,9	Pares de rótulos com $\phi > 0$	351/351

* média sobre as 10 dobras do protocolo da Seção 3.4; MeanIR/MaxIR conforme [Charte et al. 2015].

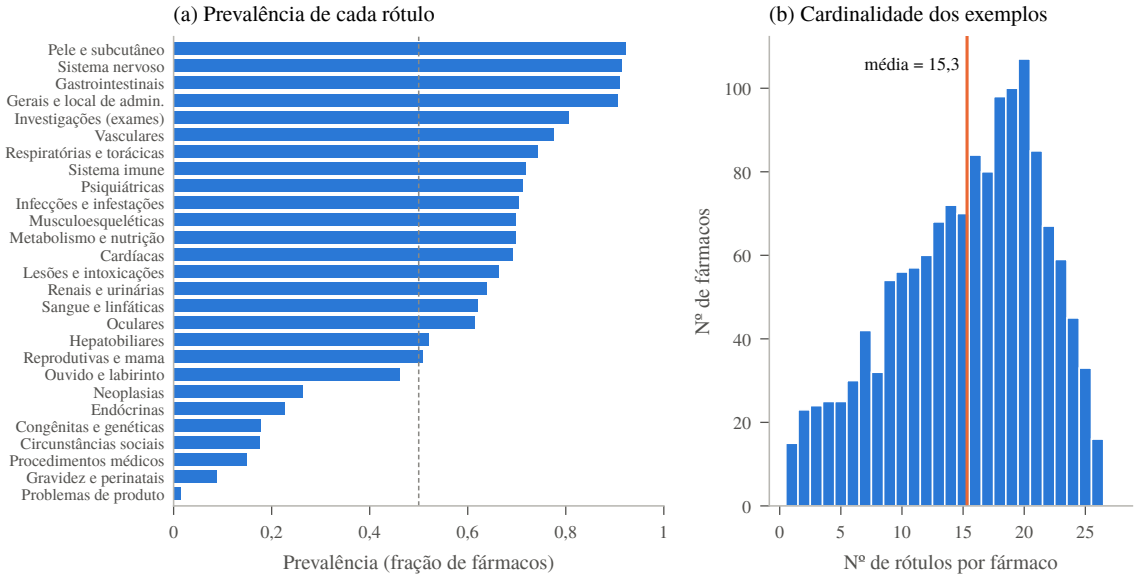


Figura 1: (a) Prevalência dos 27 rótulos; a linha tracejada marca 50%. (b) Distribuição do número de rótulos por fármaco.

Três propriedades se destacam. Primeiro, o desbalanceamento é *invertido* na maior parte dos rótulos: 19 dos 27 têm prevalência acima de 50%, de modo que a classe minoritária costuma ser a *ausência* da reação; no outro extremo, "Problemas de produto" ocorre em apenas 1,5% dos fármacos. Segundo, a dependência entre rótulos é forte e tem uma direção comum (Figura 2): o primeiro componente principal da matriz de rótulos explica sozinho 33,4% de sua variância, e a correlação média entre o número de rótulos de um fármaco e cada rótulo é 0,53. Em outras palavras, fármacos com muitas reações

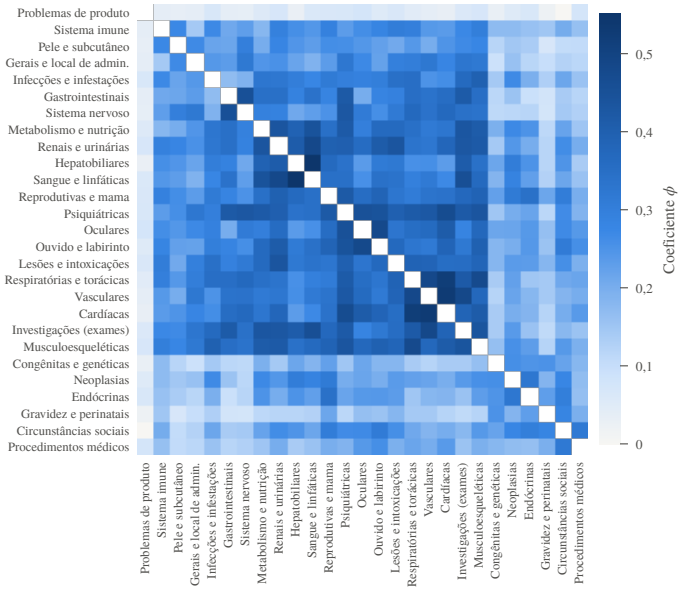


Figura 2: Correlação ϕ entre os 27 rótulos, ordenados por agrupamento hierárquico. Todas as 351 correlações são positivas.

tendem a tê-las em quase todos os sistemas — padrão compatível com a hipótese de que medicamentos mais usados e estudados acumulam bulas mais extensas. Terceiro, as combinações de rótulos são quase todas raras: em média, 69,3% dos fármacos de cada dobra de teste têm uma combinação que não aparece no treino, que o LP, por construção, nunca consegue acertar exatamente.

3.2 Representação molecular

Cada SMILES foi processado com o RDKit [Landrum 2026]. Como 182 entradas são sais ou misturas, manteve-se apenas o maior fragmento orgânico de cada molécula, evitando que contra-íons distorçam descritores como a massa molar. Foram calculados os descritores físico-químicos e topológicos 2D do RDKit (212, após remover os constantes), aos quais se aplicou a transformação $\mathrm{sinal}(v)\log(1+|v|)$ para atenuar caudas pesadas, e as 167 chaves estruturais MACCS [Durant et al. 2002], totalizando 379 atributos. Essa combinação foi escolhida num experimento preliminar com BR e validação cruzada de 5 dobras, comparando descritores, chaves MACCS, *fingerprints* de Morgan (1.024 bits) e suas combinações: com Random Forest, as cinco representações ficaram a menos de 0,015 de AUC-ROC macro entre si, e descritores+MACCS esteve entre as melhores tanto para Random Forest quanto para Regressão Logística, com um terço dos atributos da combinação com Morgan, que prejudicou o modelo linear. Como essa escolha usou os mesmos dados, ela introduz um leve otimismo comum a todos os métodos, mas não favorece nenhum deles.

3.3 Métodos avaliados

A Tabela 2 lista os dez métodos comparados. Todos produzem um escore em $[0,1]$ por rótulo, binarizado com limiar 0,5. LP, CC, RAkEL, ML-kNN e o BR empilhado foram implementados pelo autor sobre o scikit-learn [Pedregosa et al. 2011] para controlar

detalhes como a obtenção das probabilidades marginais do LP. Dois classificadores base foram usados, para verificar se as conclusões dependem do viés indutivo: *Random Forest* (RF, 100 árvores, $\sqrt{d}$ atributos por divisão) e Regressão Logística com regularização L2 ($C = 0{,}05$) sobre atributos padronizados (RL).

Tabela 2: Métodos comparados ($q = 27$ rótulos).

Método	Família	Configuração
Prior	linha de base	escore de cada rótulo = sua prevalência no treino
BR	transformação	27 classificadores binários independentes
LP	transformação	1 classificador multiclasse; escore marginal do rótulo j = soma das probabilidades das combinações que contêm j
CC	transformação	1 cadeia com ordem aleatória (10 ordens avaliadas)
CC$\times$10	ensemble	média das 10 cadeias acima, sem *bootstrap* (diversidade só de ordem)
EBR	ensemble	10 BRs em amostras *bootstrap*, média (diversidade só de reamostragem)
ECC	ensemble	10 cadeias com ordens aleatórias em amostras *bootstrap*, média
RAkEL	ensemble	$k = 3$; 6 partições aleatórias dos rótulos (54 LPs, cada rótulo em 6)
BR empilhado	*stacking*	nível 0: BR com probabilidades fora-da-dobra (5 dobras internas); nível 1: regressão logística por rótulo sobre os *logits* dos 27 escores
ML-kNN	adaptação	$k = 10$, suavização $s = 1$, distância euclidiana sobre atributos padronizados

A separação entre CC$\times$10, EBR e ECC é deliberada: como a RF já aplica *bagging* internamente, ela permite verificar se a diversidade útil vem da ordem dos rótulos, da reamostragem ou de ambas (QP3). Todos os ensembles combinam as probabilidades pela regra da média [Kittler et al. 1998].

3.4 Protocolo experimental e métricas

Usou-se validação cruzada de 10 dobras com estratificação iterativa [Sechidis et al. 2011], que preserva a proporção de cada rótulo em todas as dobras, inclusive a do rótulo raro; as mesmas dobras foram usadas para todos os métodos. Sete métricas foram calculadas no conjunto de teste de cada dobra: *Hamming loss* (HL, fração de pares exemplo–rótulo errados), acurácia exata (fração de exemplos com o vetor de rótulos inteiramente correto), índice de Jaccard médio por exemplo ($|Y_i \cap \hat{Y}_i| / |Y_i \cup \hat{Y}_i|$), F1 micro e macro, AUC-ROC macro (média da AUC por rótulo, calculada sobre os escores e, portanto, independente do limiar) e *ranking loss* (RL, fração de pares rótulo relevante/irrelevante ordenados incorretamente). Para HL e RL, menor é melhor.

Cada método foi comparado ao BR com o mesmo classificador base pelo teste t pareado com a correção de Nadeau e Bengio [Nadeau and Bengio 2003], que compensa a sobreposição entre os conjuntos de treino da validação cruzada, aplicando-se a correção de Holm às comparações de cada métrica ($\alpha = 0{,}05$). A diversidade dos en-

Tabela 3: Desempenho médio nas 10 dobras. HL e RL: menor é melhor; demais: maior é melhor. Em negrito, o melhor valor de cada bloco (sem contar o Prior); $^{\blacktriangle}/^{\triangledown}$: significativamente melhor/pior que o BR do mesmo bloco (teste t corrigido com Holm, $\alpha = 0{,}05$).

Método	HL	Ac. exata	Jaccard	F1-mi	F1-ma	AUC-ma	RL
Classificador base: Random Forest							
Prior (base trivial)	0,251	0,004$^{\triangledown}$	0,663	0,802	0,587$^{\triangledown}$	0,500$^{\triangledown}$	0,111$^{\triangledown}$
BR	0,230	0,025	0,656	0,806	0,649	0,683	0,099
LP	**0,227**	0,023	**0,668**$^{\blacktriangle}$	**0,812**	0,649	0,684	0,095
CC (1 ordem)	0,239	0,029	0,653	0,803	0,651	0,666$^{\triangledown}$	0,107$^{\triangledown}$
CC×10 (média)	0,231	**0,030**	0,661	0,809	**0,653**	0,685	0,094$^{\blacktriangle}$
EBR	0,228	0,020	0,660	0,809	0,641$^{\triangledown}$	0,683	0,092$^{\blacktriangle}$
ECC	0,230	0,023	0,662$^{\blacktriangle}$	0,810$^{\blacktriangle}$	0,645	0,682	0,093$^{\blacktriangle}$
RAkEL (k=3)	0,228	0,021	0,661	0,809	0,647	**0,689**	**0,092**$^{\blacktriangle}$
BR empilhado	0,229	0,019	0,663	0,810	0,637$^{\triangledown}$	0,670	0,097
ML-kNN (k=10)	0,237	0,012	0,662	0,806	0,623$^{\triangledown}$	0,644	0,100
Classificador base: Regressão Logística							
Prior (base trivial)	0,251	0,004	0,663$^{\blacktriangle}$	0,802$^{\blacktriangle}$	0,587$^{\triangledown}$	0,500$^{\triangledown}$	0,111
BR	0,244	0,008	0,634	0,791	0,639	0,651	0,116
LP	**0,228**$^{\blacktriangle}$	**0,024**	**0,672**$^{\blacktriangle}$	**0,814**$^{\blacktriangle}$	0,632	**0,688**$^{\blacktriangle}$	**0,093**$^{\blacktriangle}$
CC (1 ordem)	0,257	0,011	0,626	0,786	0,649	0,639	0,124$^{\triangledown}$
CC×10 (média)	0,244	0,013	0,641	0,796	**0,656**$^{\blacktriangle}$	0,656	0,112$^{\blacktriangle}$
EBR	0,242	0,005	0,637	0,793	0,636	0,657	0,113$^{\blacktriangle}$
ECC	0,240	0,007	0,643	0,799$^{\blacktriangle}$	0,650	0,659	0,109$^{\blacktriangle}$
RAkEL (k=3)	0,240	0,011	0,641$^{\blacktriangle}$	0,796$^{\blacktriangle}$	0,644	0,659$^{\blacktriangle}$	0,110$^{\blacktriangle}$
BR empilhado	0,235$^{\blacktriangle}$	0,013	0,659$^{\blacktriangle}$	0,806$^{\blacktriangle}$	0,620$^{\triangledown}$	0,651	0,102$^{\blacktriangle}$

sembles foi medida, para cada rótulo, pela medida de desacordo e pela estatística Q entre todos os pares de membros, calculadas sobre as predições binárias no teste e depois promediadas sobre pares e rótulos. O código, escrito em Python, os dados, os resultados de cada dobra e as figuras estão disponíveis em https://github.com/VitordaMata12/Aprendizado-de-Maquina-2/tree/main/Trabalho1.

4 Resultados e Discussão

4.1 Visão geral e o papel da linha de base

A Tabela 3 resume os resultados. A primeira lição vem da linha de base trivial. O Prior, que atribui a cada rótulo sua prevalência e, portanto, sempre prediz os 19 rótulos majoritários, alcança Jaccard de 0,663 e F1 micro de 0,802, próximos dos melhores métodos e acima do próprio BR em Jaccard; com RL, o Prior supera o BR de forma significativa em Jaccard e em F1 micro. Com cardinalidade alta e desbalanceamento invertido, as métricas baseadas em exemplos são dominadas pelos rótulos frequentes e discriminam mal os métodos; a acurácia exata, por sua vez, fica abaixo de 3% para todos, reflexo direto de que quase toda combinação é única. Por isso, a discussão privilegia AUC-ROC macro, F1 macro, sensível aos rótulos menos frequentes, e *ranking loss*. Em AUC-ROC e F1 macro todos os métodos superam o Prior com folga, e os valores absolutos de AUC-ROC, entre 0,63 e 0,69, confirmam a dificuldade da tarefa [Wu et al. 2018]. Na *ranking loss*, ordenar os rótulos pela prevalência já é uma referência exigente: com RL, o próprio BR fica atrás do Prior (0,116 contra 0,111).

4.2 QP1: modelar a dependência compensa?

Com Random Forest, nenhum método supera o BR de forma significativa em HL ou AUC-ROC macro, e os ganhos ficam abaixo de 0,01. Os ganhos aparecem onde a teoria prevê [Dembczyński et al. 2012]: na *ranking loss*, que avalia a ordenação conjunta dos rótulos de cada fármaco, os ensembles de cadeias, o EBR e o RAkEL reduzem significativamente a perda (de 0,099 para até 0,092), e no Jaccard, em que LP e ECC são significativamente melhores. A cadeia isolada, ao contrário, é significativamente pior que o BR em AUC-ROC e *ranking loss*: no treino, cada elo recebe os rótulos verdadeiros dos anteriores, mas no teste recebe predições binárias com erro, e esse descompasso se propaga ao longo da cadeia.

Com Regressão Logística o quadro muda: o LP lidera em seis das sete métricas, com AUC-ROC macro de 0,688 contra 0,651 do BR e *ranking loss* de 0,093 contra 0,116, e o RAkEL também melhora significativamente a AUC-ROC; com exceção da cadeia isolada, todos os métodos reduzem significativamente a *ranking loss*. A explicação está na estrutura dos rótulos: como um único fator responde por um terço da variância (Seção 3.1), saber "quantas reações" um fármaco tende a ter informa todos os rótulos ao mesmo tempo. Um modelo linear por rótulo não compartilha essa informação; o LP, ao estimar a distribuição sobre combinações inteiras e marginalizá-la, sim. A RF, que já induz interações não lineares entre atributos, tem menos a ganhar. O BR empilhado ilustra o mesmo ponto: com RL ele melhora significativamente HL, Jaccard e F1 micro, mas com RF perde em F1 macro. Inspecionando o meta-nível da versão com RF, os pesos fora da diagonal são pequenos (média de 0,014, contra 0,371 na diagonal) e pouco correlacionados com a matriz ϕ ($r = 0{,}203$): com escores de nível 0 fortemente colineares, o meta-classificador praticamente só recalibra cada rótulo. A resposta à QP1, portanto, depende do classificador base: modelar a dependência compensa sobretudo quando ele é mais rígido.

4.3 QP2: Label Powerset e o meio-termo do RAkEL

O bom desempenho do LP numa base em que 69% das combinações de teste nunca foram vistas é, à primeira vista, contraintuitivo. Ele se explica pela decodificação: em vez de devolver a combinação mais provável (a moda), o LP aqui devolve a probabilidade marginal de cada rótulo, o que lhe permite predizer combinações inéditas — de fato, 28% das combinações preditas pelo LP com RF não existem no treino. Para isolar esse efeito, o LP foi reavaliado com a decodificação pela moda, que só produz combinações vistas no treino (média de 990 classes por dobra). Com RF, a acurácia exata praticamente não muda (0,023 com as marginais e 0,024 com a moda), enquanto a HL piora de 0,227 para 0,268; com RL, o padrão é o mesmo. A teoria diz que a moda otimiza a perda 0/1 sobre o vetor inteiro e as marginais otimizam perdas por rótulo [Dembczyński et al. 2012]; aqui, porém, a vantagem da moda na acurácia exata desaparece, porque em 69% dos casos a combinação correta simplesmente não está entre as candidatas.

A Figura 3 percorre o espectro entre os dois extremos com o RAkEL, mantendo cada rótulo coberto seis vezes. Nas três métricas, valores intermediários de k superam tanto o BR quanto o LP: o melhor AUC-ROC e a menor HL ocorrem em $k = 14$ (AUC-ROC 0,008 acima do BR) e a menor *ranking loss*, em k entre 6 e 9. Subconjuntos pe-

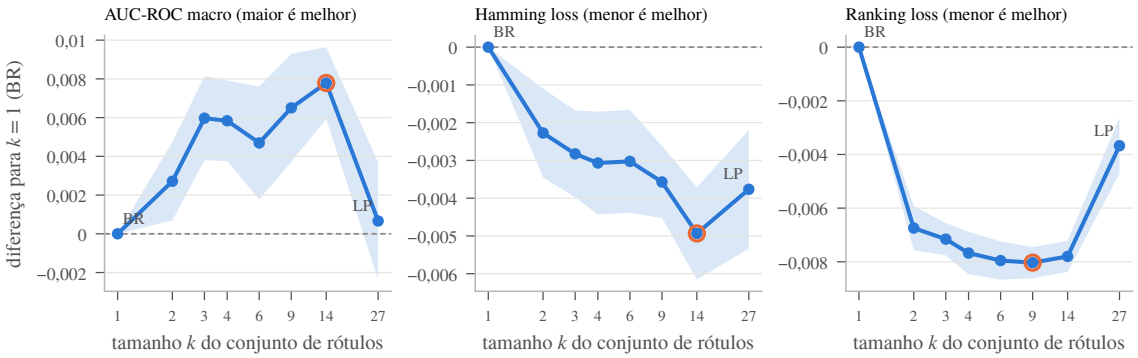


Figura 3: RAkEL com RF variando k de 1 (equivale ao BR) a 27 (equivale ao LP): diferença média pareada em relação a $k = 1$ nas 10 dobras; a faixa indica ± 1 erro-padrão e o círculo laranja, o melhor k.

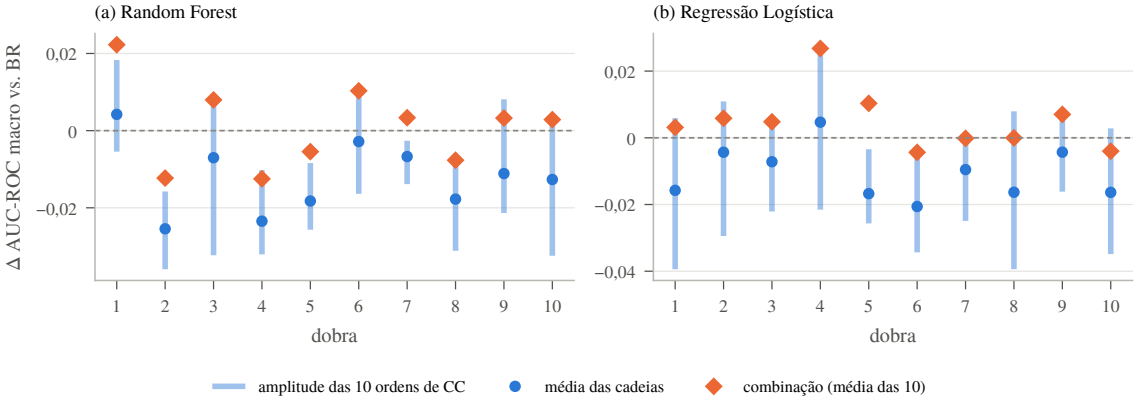


Figura 4: Diferença de AUC-ROC macro em relação ao BR, por dobra: amplitude e média das 10 cadeias com ordens aleatórias e resultado da combinação das 10 pela regra da média.

quenos já capturam a maior parte da dependência — com $k = 2$ obtém-se mais de 80% da redução máxima da *ranking loss* — sem herdar a esparsidade de classes do LP completo, cujas cerca de mil classes têm, em sua maioria, um único exemplo. Isso responde à QP2: o RAkEL de fato funciona como meio-termo, e o ponto ótimo fica longe dos dois extremos.

4.4 QP3: de onde vem a diversidade útil

A Figura 4 mostra que a ordem da cadeia pesa: a diferença entre a melhor e a pior ordem é, em média, de 0,025 de AUC-ROC com RF e 0,035 com RL — maior que a maioria das diferenças entre métodos da Tabela 3. A combinação das 10 cadeias fica acima da média dos membros em todas as dobras e, em 5 das 10 dobras com RF, acima até da melhor ordem individual, que não seria conhecida de antemão.

A Tabela 4 decompõe as fontes de diversidade. A variação de ordem é a fonte mais "barata": cadeias com ordens diferentes concordam muito ($Q = 0{,}99$ com RF), mas cada membro usa todos os dados de treino e é, por isso, forte; o resultado é o ensemble com a maior acurácia exata e o maior F1 macro do bloco RF. O *bootstrap* gera quase o dobro de desacordo e ganhos maiores sobre os membros (0,027 e 0,031 de AUC-ROC),

Tabela 4: Diversidade e ganho da combinação (médias nas 10 dobras). Desacordo e Q calculados por rótulo entre pares de membros; ganho = AUC-ROC do ensemble menos a AUC-ROC média dos membros.

				AUC-ROC macro			F1 micro	
Base	Ensemble	Desacordo	Q	membros	ensemble	ganho	membros	ensemble
RF	CC×10 (só ordem)	0,054	0,99	0,671	0,685	+0,013	0,806	0,809
RF	EBR (só bootstrap)	0,094	0,96	0,656	0,683	+0,027	0,801	0,809
RF	ECC (ordem + bootstrap)	0,095	0,96	0,652	0,682	+0,031	0,803	0,810
LR	CC×10 (só ordem)	0,111	0,95	0,640	0,656	+0,016	0,783	0,796
LR	EBR (só bootstrap)	0,146	0,90	0,632	0,657	+0,025	0,777	0,793
LR	ECC (ordem + bootstrap)	0,181	0,84	0,624	0,659	+0,035	0,771	0,799

mas boa parte desse ganho apenas recupera o que a reamostragem tirou: com RF, que já é um ensemble por *bagging*, um membro treinado em cerca de 63% de exemplos distintos perde 0,032 de AUC-ROC em relação ao BR. Com RL a situação se inverte em parte: por ser um algoritmo estável, a regressão logística quase não se beneficia do *bootstrap* sozinho (EBR), mas a combinação de ordem e reamostragem (ECC) produz a maior diversidade ($Q = 0{,}84$) e o melhor ensemble de cadeias em AUC-ROC e *ranking loss*, em linha com a observação clássica de que a reamostragem favorece algoritmos instáveis [Breiman 1996] — aqui, a instabilidade vem da própria cadeia. A resposta à QP3 é, portanto, condicional: com um classificador base já diversificado, a ordem é a fonte útil; com um classificador estável, ordem e reamostragem se complementam.

4.5 Limitações

Os resultados devem ser lidos com quatro ressalvas: (i) usou-se uma única base e uma única representação molecular; (ii) os hiperparâmetros foram fixados *a priori*, sem busca aninhada, e a escolha da representação usou os mesmos dados; (iii) o limiar de 0,5 é o mesmo para todos os rótulos, e limiares calibrados por rótulo poderiam beneficiar o F1 macro; e (iv) na SIDER, a ausência de registro em bula não prova a ausência da reação — os negativos são, a rigor, exemplos não rotulados, o que aproxima o problema do aprendizado positivo e não rotulado (PUL).

5 Conclusão

Este trabalho comparou estratégias de classificação multirrótulo e de combinação de modelos na predição, a partir da estrutura molecular, de reações adversas em 27 sistemas do organismo. Três lições se destacam. Primeiro, com cardinalidade alta e desbalanceamento invertido, as métricas baseadas em exemplos são enganosas — uma linha de base trivial fica próxima dos melhores métodos em Jaccard e F1 micro e supera o BR em Jaccard —, de modo que AUC-ROC macro, F1 macro e *ranking loss* devem guiar a avaliação. Segundo, explorar a dependência entre rótulos pouco acrescenta a um BR com Random Forest nas métricas por rótulo, mas melhora a ordenação conjunta e rende ganhos grandes quando o classificador base é linear, caso em que o LP com decodificação marginal foi o melhor método. Terceiro, o RAkEL com k intermediário supera os dois extremos que ele interpola, e em ensembles de cadeias a fonte útil de diversidade

depende da estabilidade do classificador base. Como trabalhos futuros, propõem-se a calibração de limiares por rótulo, representações aprendidas, como redes neurais em grafos, e a reformulação do problema como aprendizado positivo e não rotulado.

Referências

Boutell, M. R., Luo, J., Shen, X., and Brown, C. M. (2004). Learning multi-label scene classification. *Pattern Recognition*, 37(9):1757–1771.

Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2):123–140.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Charte, F., Rivera, A. J., del Jesus, M. J., and Herrera, F. (2015). Addressing imbalance in multilabel classification: measures and random resampling algorithms. *Neurocomputing*, 163:3–16.

Dembczyński, K., Waegeman, W., Cheng, W., and Hüllermeier, E. (2012). On label dependence and loss minimization in multi-label classification. *Machine Learning*, 88(1–2):5–45.

Durant, J. L., Leland, B. A., Henry, D. R., and Nourse, J. G. (2002). Reoptimization of MDL keys for use in drug discovery. *Journal of Chemical Information and Computer Sciences*, 42(6):1273–1280.

Faceli, K., Lorena, A. C., Gama, J., Almeida, T. A., and Carvalho, A. C. P. L. F. (2021). *Inteligência Artificial: uma Abordagem de Aprendizado de Máquina*. LTC, Rio de Janeiro, 2. ed.

Godbole, S. and Sarawagi, S. (2004). Discriminative methods for multi-labeled classification. In *Advances in Knowledge Discovery and Data Mining (PAKDD)*, volume 3056 of *LNCS*, pages 22–30. Springer.

Hansen, L. K. and Salamon, P. (1990). Neural network ensembles. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 12(10):993–1001.

Kittler, J., Hatef, M., Duin, R. P. W., and Matas, J. (1998). On combining classifiers. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(3):226–239.

Kuhn, M., Letunic, I., Jensen, L. J., and Bork, P. (2016). The SIDER database of drugs and side effects. *Nucleic Acids Research*, 44(D1):D1075–D1079.

Kuncheva, L. I. and Whitaker, C. J. (2003). Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy. *Machine Learning*, 51(2):181–207.

Landrum, G. (2026). RDKit: open-source cheminformatics, versão 2026.03. Disponível em: https://www.rdkit.org.

Lazarou, J., Pomeranz, B. H., and Corey, P. N. (1998). Incidence of adverse drug reactions in hospitalized patients: a meta-analysis of prospective studies. *JAMA*, 279(15):1200–1205.

Nadeau, C. and Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Read, J., Pfahringer, B., Holmes, G., and Frank, E. (2011). Classifier chains for multi-label classification. *Machine Learning*, 85(3):333–359.

Sechidis, K., Tsoumakas, G., and Vlahavas, I. (2011). On the stratification of multi-label data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, volume 6913 of *LNCS*, pages 145–158. Springer.

Tsoumakas, G., Katakis, I., and Vlahavas, I. (2011). Random k-labelsets for multilabel classification. *IEEE Transactions on Knowledge and Data Engineering*, 23(7):1079–1089.

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2):241–259.

Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., and Pande, V. (2018). MoleculeNet: a benchmark for molecular machine learning. *Chemical Science*, 9(2):513–530.

Zhang, M.-L. and Zhou, Z.-H. (2007). ML-KNN: a lazy learning approach to multi-label learning. *Pattern Recognition*, 40(7):2038–2048.

Zhang, M.-L. and Zhou, Z.-H. (2014). A review on multi-label learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8):1819–1837.

Zhang, W., Liu, F., Luo, L., and Zhang, J. (2015). Predicting drug side effects by multi-label learning and ensemble learning. *BMC Bioinformatics*, 16:365.